Computer Vision — Assignment 2

2023036299 김진욱

Proposal Report — X-Pool: Cross-Modal Language-Video Attention for Text-Video Retrieval

GitHub : https://github.com/ApeachLicense/X_Pool_Experiment

1. Topic & Dataset

1.1 연구 주제와 배경

X-Pool은 텍스트 질의가 주어졌을 때, 여러 영상 중에서 질의와 의미가 맞는 영상을 찾아내는 text-to-video retrieval이다. 이 문제의 어려움은 단순히 캡션과 영상을 매칭하는 데 있지 않고, 근본적으로 영상이 캡션보다 훨씬 많은 정보를 담고 있다는 데 있다. 그래서 캡션 하나는 영상의 일부 장면만 설명하게 되고, 같은 영상에 달린 캡션들은 서로 다른 장면을 가리키는 one-to-many 관계가 되며 이들은 모두 정답이다. 그런데 mean pooling처럼 질의와 무관하게 프레임을 하나의 벡터로 합치면 모든 장면이 섞이기 때문에, 특정 캡션 입장에서는 설명하지 않은 장면이 노이즈가 되어 정답 영상과의 유사도가 떨어진다. X-Pool은 이를 해결하기 위해 질의에 대응되는 프레임에 집중해 영상 표현을 질의마다 다르게 만들고, 이를 통해 검색 성능을 향상시킨다 [1].

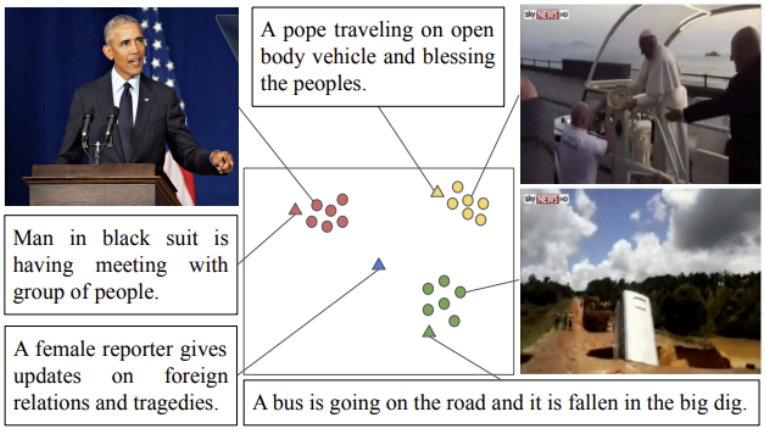


Figure 1. Illustration of the joint text and visual representations for a single video and its captions taken verbatim from the MSR-VTT dataset. Since the video is capturing more content than each individual text, aggregating the entire video regardless of the input text can be misleading.

1.2 주제 선정 과정

컴퓨터 비전을 공부하면서 colorization, 2D 이미지로부터의 3D 복원처럼 입력 하나에 그럴듯한 답이 여러 개인 one-to-many 문제를 여러 번 접했다. 이런 문제들은 입력이 출력보다 정보를 덜 담고 있다는 공통점이 있는데(흑백 이미지에는 색이, 2D 이미지에는 깊이가 없다), 텍스트가 영상의 일부만 설명한다는 점에서 text-to-video retrieval도 같은 구조라는 점이 흥미로웠다. 그래서 질의가 가리키는 장면에 집중해 영상 표현을 만드는 X-Pool을 기준 모델로 골랐다. 또한 CLIP ViT-B/32 기반이라 배치를 4로 줄이면 개인 컴퓨터의 8 GiB GPU에서도 학습·평가할 수 있다는 점을 고려했다.

1.3 벤치마크 데이터셋: MSR-VTT

영상 10,000개에 영상당 사람이 쓴 캡션 20개가 붙은 비상업적 이용이 한정되어 있는 데이터셋으로, 영상 당 길이는 약 10~32초다 [4]. 학습은 9k-Train(영상 9,000개, 180,000쌍), 평가는 1K-A(영상 1,000개, 1,000쌍)으로 진행된다 [1]. 분할과 캡션 주석은 공식 X-Pool 저장소의 파일을, 영상은 Oxford(Frozen in Time) 배포본

MSRVTT.zip을 사용했다 [5,6]. 영상 10,000개는 다운로드 후 CRC32를 확인했다. 전처리는 영상당 12프레임을 균등 간격으로 뽑아,

평가에서는 224×224 중앙 crop을, 학습에서는 RandomResizedCrop과 좌우 반전을 적용하고 텍스트는 CLIP 토크나이저로 변환한다 [1,5].

논문은 별도 validation 분할을 두지 않고, 공식 코드는 학습 중 1K-A로 평가해 가장 좋은 체크포인트를 저장한다 [1,5]. 본 프로젝트는 평가 없이 마지막 epoch을 쓰고 개선 후보를 고를 때는 9K 내부 검증 분할을 쓴다.

캡션 중복(같은 영상 안 7.4%, 서로 다른 영상 사이 13.4%)은 제거하지 않았고, 1K-A에는 같은 캡션이 여러 영상에 쓰인 질의가 9개 있다.

1.4 데이터 축소 및 연산 자원 계획

Windows OS에서 RTX 3060 Ti(VRAM 8GiB), 시스템 메모리 32GB로 프로젝트를 수행할 예정이며,

X-Pool 공식 저장소의 의존성에 맞춰 환경을 구성했다(Python 3.9.18, PyTorch 1.8.1(cu 111), Transformers 4.6.1) [5].

학습 데이터를 줄이는 대신, VRAM 한도로 인하여 배치 사이즈를 4로 줄이고, FP32로 학습을 진행할 예정이다.

2. 관련 논문 리뷰 **(Related Paper Review)**

2.1 CLIP과 기존 **Video Pooling**

X-Pool은 CLIP을 backbone으로 쓴다. CLIP의 텍스트 인코더 ψ와 이미지 인코더 φ는 텍스트와 이미지를 같은 임베딩 공간에 놓는다 [2]. 그래서 텍스트는 c_t = ψ(t)로, 영상은 프레임마다 c_v^f = φ(v^f)로 임베딩하고, 영상 전체는 프레임 임베딩 행렬 $C_v \in \mathbb{R}^{F\times D}$로 표현한다. 텍스트 쪽은 CLIP의 출력을 그대로 쓰므로 $z_t = c_t$이고, 영상 쪽은 F개의 프레임 임베딩을 하나의 벡터 z_v = ρ(C_v)로 합쳐야 한다. 기존 방법들은 이 집계 함수 ρ를 mean pooling, self-attention, LSTM 등으로 달리 정한다 [1,3].

이 ρ는 프레임만의 함수여서 질의 텍스트를 보지 않는다. 같은 영상은 어떤 캡션이 오든 같은 z_v가 되는데, 캡션은 영상의 일부 장면만 설명하므로 z_v에는 캡션이 말하지 않은 장면의 정보까지 섞여 유사도를 떨어뜨린다 [1].

2.2 Text-conditioned pooling과 **top-k**

영상 임베딩을 텍스트에 조건화($z_{v|t}$ = π(C_v | t))하고 z_t와 $z_{v|t}$의 코사인 유사도를 s(t, v)로 사용한다. 같은 영상이라도 질의가 다르면 모아지는 프레임이 달라지므로, 캡션마다 영상의 다른 장면을 가리키는 one-to-many 구조에 맞는 표현이 된다 [1].

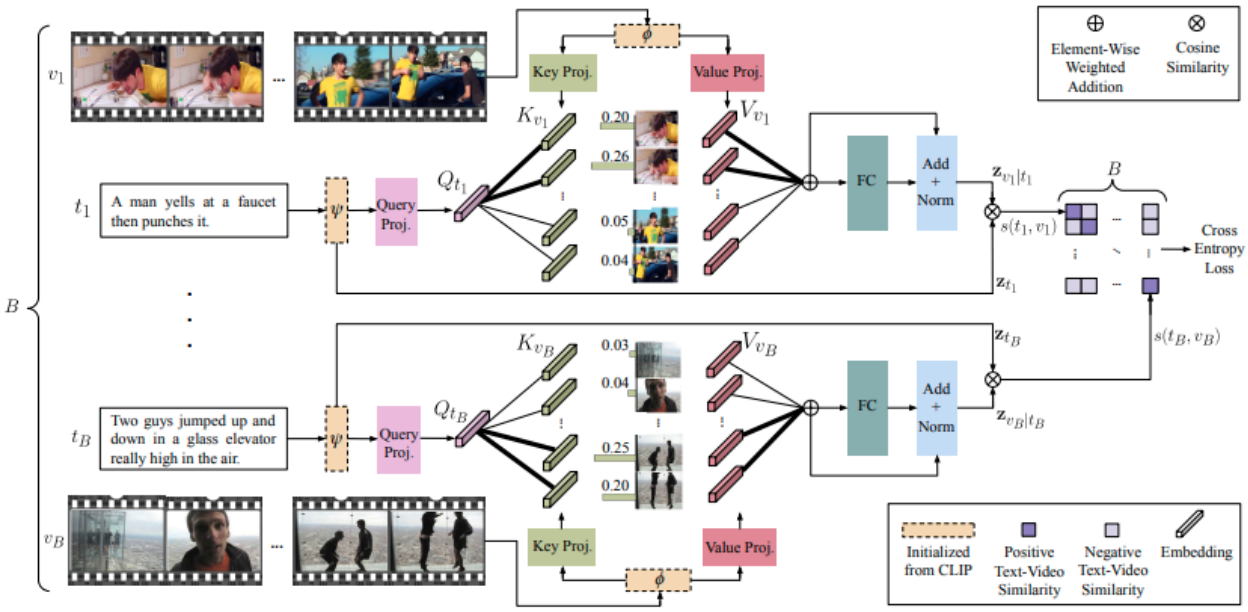
텍스트와 코사인 유사도가 가장 높은 k개 프레임 임베딩만 평균 내는 방식인 top-k pooling에서는 k=3일 때 MSR-VTT에서 mean pooling 대비 R@1이 제로샷 31.5→33.6, 파인튜닝 42.1→44.6으로 올라, 질의에 맞는 프레임만 모아도 효과가 있음을 보여줬다 [1].

다만, 텍스트-영상 pair마다 최적의 k가 크게 달라 고정하기 어렵고, 프레임을 단순히 코사인 유사도 하나만으로 고른다는 점과 top-k에 선택되지 않은 프레임은 그대로 활용되지 않는다는 한계가 존재한다 [1].

2.3 Cross-Attention 기반 Pooling

X-Pool은 질의에 맞는 프레임을 고르기 위해 Cross-Attention으로 학습한다. 텍스트 임베딩 c_t는 Query $Q_t \in \mathbb{R}^{1\times D_p}$로, 프레임 임베딩 C_v는 Key K_v와 Value $V_v \in \mathbb{R}^{F\times D_p}$로 투영한다(각각 LayerNorm 후 W_Q, W_K, W_V를 적용). Query는 영상에서 찾고자 하는 것이고, Key는 프레임마다 Query와 비교되는 표현, Value는 실제로 합쳐질 프레임의 내용이다. K와 V는 같은 프레임 임베딩에서 나오지만 투영이 따로여서, 비교에 쓰는 표현과 집계에 쓰는 표현을 분리할 수 있다 [1].

$$\text{Attention}(Q_t, K_v, V_v) = \text{softmax}\left(\frac{Q_t K_v^{\top}}{\sqrt{D_p}}\right) V_v$$



Q_t와 K_v의 내적에 softmax를 취하면 프레임 F개에 대한 가중치(합이 1)가 나오고, 이 가중치로 V_v를 가중합하면 질의와 관련 있는 프레임이 더 크게 반영된 영상 표현이 하나 나온다. 여기에 출력 투영 W_O, LayerNorm, FC와 residual connection을 거쳐 $z_{v|t}$를 만들고, z_t와의 코사인 유사도로 s(t, v)를 계산한다 [1].

top-k가 k개 프레임만 골라 나머지를 버렸다면, X-Pool은 모든 프레임에 연속적인 가중치를 준다. 그래서 k를 정할 필요가 없고, 프레임의 관련도를 코사인 대신 학습된 투영으로 판단하며, 관련이 낮은 프레임도 0이 아니라 작은 가중치로 남는다 [1].

2.4 학습 목적 함수

학습은 배치 B개의 텍스트-영상 쌍으로 B×B 유사도 행렬 s(t_i, v_j)를 만들어 진행한다. 대각선(i=j)의 짝이 정답(positive)이고, 같은 배치의 나머지 조합은 모두 negative다. L_{t2v}는 텍스트 t_i를 고정하고, B개의 영상 중 짝인 v_i에 가장 높은 확률이 가도록 하는 cross-entropy다. L_{v2t}는 반대로 영상을 고정하고 B개의 텍스트 중에서 짝을 맞히게 한다. 두 손실을 더한 L = L_{t2v} + L_{v2t}를 최종 목적함수로 쓴다. 유사도에는 학습 가능한 scaling 값 λ가 곱해지고, 초기값은 사전학습된 CLIP의 것을 쓴다 [1].

$$\mathcal{L}_{t2v} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{e^{s(t_i,v_i)\cdot\lambda}}{\sum_{j=1}^{B} e^{s(t_i,v_j)\cdot\lambda}} \qquad \mathcal{L}_{v2t} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{e^{s(t_i,v_i)\cdot\lambda}}{\sum_{j=1}^{B} e^{s(t_j,v_i)\cdot\lambda}}$$

X-Pool에서는 영상 표현 $z_{v|t}$가 텍스트마다 달라지므로, 행렬의 칸 s(t_i, v_j)마다 pooling을 따로 해야 한다(배치당 B^2번) [1].

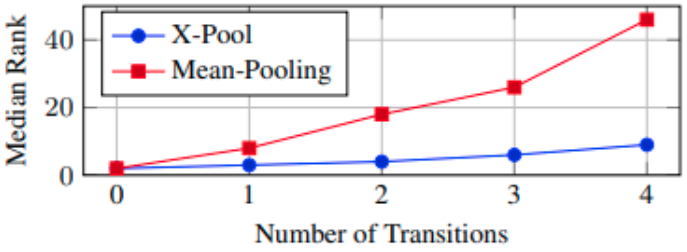
2.5 실험 결과

성능은 질의 1,000개 각각에 대해 후보 영상 1,000개를 유사도 순으로 정렬했을 때 정답 영상의 순위로 평가한다. R@K는 정답이 상위 K위 안에 든 질의의 비율이고(높을수록 좋다), MedR과 MeanR는 정답 순위의 중앙값과 평균이다(낮을수록 좋다) [1].

CLIP4Clip-meanP [29]	43.1	70.4	80.8	**2.0**	16.2
CLIP4Clip-seqTransf [29]	44.5	71.4	81.6	**2.0**	15.3
X-Pool (ours)	**46.9**	**72.8**	**82.2**	**2.0**	**14.3**

Table 1. $t2v$ results on the MSR-VTT-9K dataset.

X-Pool은 테스트 영상에 다른 영상을 무작위로 끼워 장면 전환 횟수를 늘린 환경에서도 Mean Pooling에 비해 강건한 모습을 보였다 [1].



3. 계획

사전 실험에서 공식 체크포인트를 1K-A로 평가하자 논문에 보고된 R@1 46.9% [1]와 동일한 결과가 나왔고, 공식 학습 명령을 따르되 배치를 4로 줄여 5 epoch 직접 학습한(학습률·dropout은 동일) 모델은 R@1 39.9%로 7.0%p 낮은 수치를 기록했다. 배치크기 외에도 업데이트 횟수등을 다르게 두었기 때문에 수치 하락의 원인을 단정할 수 없다.

프로젝트의 목표는 VRAM 8GiB 환경에서 배치 4로 학습한 X-Pool이 이 격차를 줄여, 논문 설정(배치 32)의 공식 체크포인트에 가까워지도록 하는 것이다. 배치 4에서의 점수를 올리는 데 그치지 않고, 메모리 부족으로 큰 배치를 쓰지 못하는 contrastive 학습의 사례와 최적화 기법을 조사해 X-Pool에 적용해보고자 한다.

3.1 재현 소스 코드 분석

배치를 32에서 4로 줄이며 생기는 한계를 분석한다. 격차의 원인 후보에는 배치 크기 외에 업데이트 횟수와 체크포인트 선택 방식도 있어, 배치 크기의 영향이 실제로 어느 정도인지부터 확인한다. 단서로, 공식 체크포인트가 1위로 맞힌 질의 중 직접 학습 모델이 놓친 119개의 대부분(98개)은 정답이 2~5위였고, 학습 중 비교하는 negative가 질의당 31개에서 3개로 줄어든 영향일 가능성이 있다. 다만 2~5위에는 정답으로 지정되지 않았을 뿐 질의에 맞는 영상도 섞여 있을 수 있어 이를 구분해 보고, attention 분포의 분석도 이 단계에서 함께 진행하고자 한다.

3.2 선행 연구 조사

최근 제안된 최적화 기법을 조사하고, VRAM 8GiB와 공식 코드 구조(PyTorch 1.8.1)에서 적용 가능한지 확인한다.

중간 보고까지는 3.1·3.2의 분석과 조사 결과, 그리고 적용할 후보와 소규모 시험 결과를 정리하고, 최종 보고까지는 선택한 기법을 적용한 전체 학습 결과와 비교를 정리하는 것을 목표로 한다.

References

[1] Gorti et al., X-Pool: Cross-Modal Language-Video Attention for Text-Video Retrieval, CVPR, 2022. https://arxiv.org/abs/2203.15086

[2] Radford et al., Learning Transferable Visual Models from Natural Language Supervision, ICML, 2021. https://arxiv.org/abs/2103.00020

[3] Luo et al., CLIP4Clip: An Empirical Study of CLIP for End to End Video Clip Retrieval, arXiv:2104.08860, 2021. https://arxiv.org/abs/2104.08860

[4] Xu et al., MSR-VTT: A Large Video Description Dataset for Bridging Video and Language, CVPR, 2016.

[5] layer6ai-labs, xpool (official implementation), GitHub, commit bc88718. https://github.com/layer6ai-labs/xpool

[6] Bain et al., Frozen in Time: A Joint Video and Image Encoder for End-to-End Retrieval, arXiv:2104.00650, 2021. https://arxiv.org/abs/2104.00650